

アルゴリズム論 1

第 3 回

正規表現と有限オートマトンの関係

関川 浩

2017/04/26

第 1 回から第 3 回の内容

言語理論とオートマトンの主題

無限集合である言語をいかに表現するか

一つの方法:

言語が満たすルールをうまく書いて, それを言語の表現とする手法.
文法がその代表

第 1 回: **正規表現**というシステムを紹介

第 2 回: **有限オートマトン**という表現法を紹介

第 3 回: 正規表現と有限オートマトン (見掛けはかなり違う) は
言語の表現能力が等しいことを証明

有限オートマトン (正規表現) の**能力の限界**を説明

① 有限オートマトンと正規表現の等価性

- fa と正規表現の等価性の証明手順
- nfa の dfa による模倣
- ϵ nfa の nfa による模倣
- 正規表現と ϵ nfa の関係
- nfa と正規表現の関係
- fa と正規表現の等価性

② 有限オートマトンの能力の限界

- fa, 正規表現の言語表現能力
- 正規言語ではない言語の存在

- ① 有限オートマトンと正規表現の等価性
- ② 有限オートマトンの能力の限界

fa と正規表現の等価性の証明手順

等価性: 言語の表現能力が等しいこと

fa と正規表現の等価性 (定理 1) の証明手順:

- ① dfa と nfa の等価性, nfa と ϵ nfa の等価性を証明.
dfa は nfa で, nfa は ϵ nfa なので, 以下を示せば十分
 - nfa が dfa で模倣できること (補題 1)
 - ϵ nfa が nfa で模倣できること (補題 2)
- ② fa と正規表現の等価性を証明. 以下を示す
 - 正規表現が ϵ nfa で模倣できること (補題 3)
 - nfa が正規表現で模倣できること (補題 4)

nfa の dfa による模倣 (1/2)

補題 1

言語 L が nfa で認識可能なら, L は dfa で認識可能

証明

nfa $N = (K, \Sigma, \delta, s_0, F)$: L を認識


L を認識する dfa $D = (2^K, \Sigma, \delta', \{s_0\}, F')$ を構成

- D の状態は N の状態集合の部分集合
- $\delta'(S, a) \stackrel{\text{def}}{=} \bigcup_{s \in S} \delta(s, a) \quad (S \subseteq K, a \in \Sigma)$
- $F' \stackrel{\text{def}}{=} \{S \mid S \subseteq K, S \cap F \neq \emptyset\}$

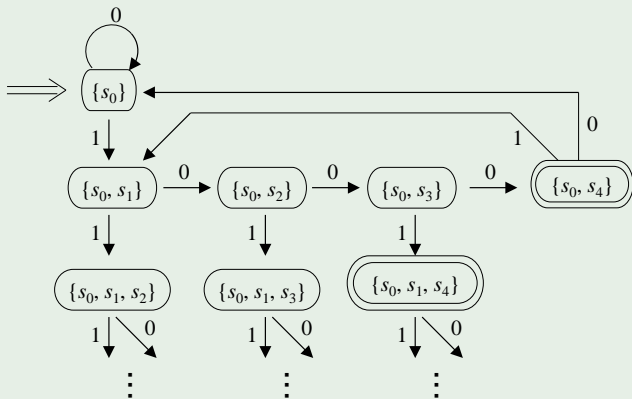
$\Rightarrow D$ は N と同じ言語を認識

nfa の dfa による模倣 (2/2)

nfa:



fa:



ϵ nfa の nfa による模倣 (1/2)

補題 2

言語 L が ϵ nfa で認識可能なら, L は nfa で認識可能

証明

ϵ nfa $E = (K, \Sigma, \delta, s_0, F)$: L を認識

L を認識する nfa $N = (K', \Sigma, \delta', s'_0, F')$ を構成


$S(s) \stackrel{\text{def}}{=} \{s\} \cup \{s \text{ から } \epsilon \text{ 遷移のみで到達できる状態}\}$

- $K' \stackrel{\text{def}}{=} \{(s, S(s)) \mid s \in K\}$
- $s'_0 \stackrel{\text{def}}{=} (s_0, S(s_0))$
- $\delta'((s, S(s)), a) \stackrel{\text{def}}{=} \left\{ (t, S(t)) \mid t \in \bigcup_{s' \in S(s)} \delta(s', a) \right\}$
- $F' \stackrel{\text{def}}{=} \{(s, S(s)) \mid S(s) \cap F \neq \emptyset\}$


$\implies N$ は E と同じ言語を認識

ϵ nfa の nfa による模倣 (2/2)

ϵ nfa:



nfa:



正規表現と ϵ nfa の関係 (1/5)


補題 3

言語 L が正規表現で表現可能なら, L は ϵ nfa で認識可能


証明 (1/5)

L : アルファベット Σ 上の正規表現 R で表現

- ① $R = \emptyset$ のとき, $L(R) (= \emptyset)$ は下図の nfa で認識可能





- ② $R = a \in \Sigma$ のとき, $L(R) (= \{a\})$ は下図の nfa で認識可能



正規表現と ϵ nfa の関係 (2/5)

証明 (2/5)

- ③ R_1, R_2 : 正規表現
 M_1, M_2 : $L(R_1), L(R_2)$ を認識する ϵ nfa




$L(R_1 + R_2), L(R_1 R_2), L(R_1^*)$ を認識する ϵ nfa を構成すればよい

正規表現と ϵ nfa の関係 (3/5)

証明 (3/5)


- $L(R_1 + R_2) (= L(R_1) \cup L(R_2))$ を認識する ϵ nfa:



正規表現と ϵ nfa の関係 (4/5)

証明 (4/5)


- $L(R_1R_2) (= L(R_1) \cdot L(R_2))$ を認識する ϵ nfa:



正規表現と ϵ nfa の関係 (5/5)

証明 (5/5)

- $L(R_1^*) (= L(R_1)^*)$ を認識する ϵ nfa:



nfa と正規表現の関係 (1/5)

補題 4

言語 L が nfa で認識可能なら, L は正規表現によって表現可能

証明 (1/5)

nfa N が認識する言語を $\tilde{L}(N)$ と書く

N における状態遷移を表す矢印の数による帰納法

- 矢印の数が 0 のとき
 - $s_0 \in F$ のとき $\tilde{L}(N) = \{\varepsilon\} = L(\emptyset^*)$
 - $s_0 \notin F$ のとき $\tilde{L}(N) = \emptyset = L(\emptyset)$

\implies 成立

証明 (2/5)

- 矢印の数が n のとき成立と仮定して $n + 1$ のとき

$x \in \tilde{L}(N) \iff s_0$ から x の記号にしたがって
うまく矢印をたどれば受理状態に到達

受理状態に到達する道筋を **パス** と呼ぶ (矢印の列で書ける)

α : N の一つの矢印 (s から s' への a による遷移とする)

N' : N から α を取り除いた nfa


$x \in \tilde{L}(N)$ とし, そのことを表すパスの一つを p とする

(a) p が α を含まないなら $x \in \tilde{L}(N')$

証明 (3/5)

(b) p が α をちょうど m 個 ($m \geq 1$) 含むなら, p は,

- s_0 から α を通らずに s へ,
- 「 s から α を通って s' へ, s' から α を通らずに s へ」を $m - 1$ 回,
- s から α を通って s' へ, s' から α を通らずに受理状態に到達




nfa と正規表現の関係 (4/5)

証明 (4/5)

$N'(t, G)$: N' の初期状態を t に, 受理状態集合を G に変えた nfa

(a), (b) より, $\tilde{L}(N)$ は以下と等しい

$$\tilde{L}(N') \cup \left(\tilde{L}(N'(s_0, \{s\})) \cdot \left(\{a\} \cdot \tilde{L}(N'(s', \{s\})) \right)^* \cdot \{a\} \cdot \tilde{L}(N'(s', F)) \right)$$



証明 (5/5)

$$\tilde{L}(N) = \tilde{L}(N') \cup \left(\tilde{L}(N'(s_0, \{s\})) \cdot \left(\{a\} \cdot \tilde{L}(N'(s', \{s\})) \right)^* \cdot \{a\} \cdot \tilde{L}(N'(s', F)) \right)$$

帰納法の仮定より, ある正規表現 R_1, R_2, R_3, R_4 が存在して,

$$\begin{aligned} \tilde{L}(N') &= L(R_1), & \tilde{L}(N'(s_0, \{s\})) &= L(R_2), \\ \tilde{L}(N'(s', \{s\})) &= L(R_3), & \tilde{L}(N'(s', F)) &= L(R_4). \end{aligned}$$

よって,

$$\begin{aligned} \tilde{L}(N) &= L(R_1) \cup (L(R_2) \cdot (L(a) \cdot L(R_3))^* \cdot L(a) \cdot L(R_4)) \\ &= L(R_1) \cup (L(R_2) \cdot L((aR_3)^*) \cdot L(a) \cdot L(R_4)) \\ &= L(R_1) \cup L(R_2(aR_3)^*aR_4) \\ &= L(R_1 + R_2(aR_3)^*aR_4) \end{aligned}$$

fa と正規表現の等価性 (1/2)

定理 1

fa と正規表現は等価

(\iff fa で認識可能な言語は正規表現で表現可能,
逆に, 正規表現で表現可能な言語は fa で認識可能)

証明

補題 3, 4 より成立

fa と正規表現の等価性 (2/2)

定理 2

L_1, L_2 : Σ 上の言語

- ① L_1, L_2 が正規表現で表現可能なら, 以下も同様

$$L_1 \cup L_2, \quad L_1 \cap L_2, \quad \Sigma^* \setminus L_1, \quad L_1 L_2, \quad L_1^*$$

- ② L_1, L_2 が fa で認識可能なら, 以下も同様

$$L_1 \cup L_2, \quad L_1 \cap L_2, \quad \Sigma^* \setminus L_1, \quad L_1 L_2, \quad L_1^*$$

証明

- 定理 1 (fa と正規表現の等価性)
- 第 1 回の定理 1
(L_1, L_2 が正規表現で表現可能なら $L_1 \cup L_2, L_1 L_2, L_1^*$ も同様)
- 第 2 回の定理 1 (L_1, L_2 が fa で認識可能なら $L_1 \cap L_2$ も同様)
定理 3 (L が fa で認識可能なら $\Sigma^* \setminus L$ も同様)

より成立

- ① 有限オートマトンと正規表現の等価性
- ② 有限オートマトンの能力の限界

fa, 正規表現の言語表現能力

fa, 正規表現: 簡潔で分かりやすく, 実用性も高い

- fa: 状態遷移図の形でいろいろな場面で利用
- 正規表現: 文字列を表現する道具として UNIX の一部分

しかし, 言語表現能力はあまり高くない

- 理由: fa の状態が有限個しかないから
- たとえば, カッコ文 (第 1 回の例) は fa では認識できない

定義 1 (正規言語)

fa によって認識できる言語 (正規表現で表現できる言語) を正規言語という

正規言語ではない言語の存在

定理 3

言語 $L = \{0^n 1^n \mid n \geq 0\}$ は正規言語ではない

証明

L がある fa $M = (K, \{0, 1\}, \delta, s_0, F)$ で認識できたと仮定

m : M の状態数

$$t_i \stackrel{\text{def}}{=} \delta(s_0, 0^i) \quad (i \geq 0)$$

$\implies t_0, t_1, \dots, t_m$ の中には同じ状態が存在

$$t_j = t_{j+k} \quad (k > 0) \text{ とする}$$

$0^j 1^j$ は受理されるので, $\delta(t_j, 1^j) \in F$

$\implies \delta(t_{j+k}, 1^j) = \delta(t_j, 1^j) \in F$ より $0^{j+k} 1^j \in L$ となり矛盾